

单位代码： 10293 密 级： 234

南京邮电大学
专业学位论文



论文题目： 基于深度学习的 Massive MIMO 信道估计与信号检测方法研

学 号	周圣坤
姓 名	张三
导 师	李四
专业学位类别	电子信息
类 型	网络空间安全
专业（领域）	新一代信息技术
论文提交日期	2026 年 6 月 14 日

摘要

Massive MIMO 通过在基站侧配置大规模天线阵列，为提升频谱效率、能量效率和空间复用能力提供了重要技术基础。然而，天线规模扩大、用户密度提升以及传播环境复杂化，使信道估计和信号检测面临更高维度、更强干扰和更严格实时性的挑战。传统最小二乘、线性最小均方误差和迭代检测方法具有清晰的理论解释，但在导频污染、空间相关、低信噪比和非理想硬件条件下，性能与复杂度之间仍存在明显矛盾。围绕上述问题，本文研究基于深度学习的 Massive MIMO 信道估计与信号检测方法，尝试利用数据驱动模型对无线信道的结构特征和检测过程中的非线性映射进行学习。

本文首先梳理 Massive MIMO 系统模型、导频训练机制、信道估计准则和上行信号检测基础，分析传统方法在复杂信道条件下的适用边界。随后，面向块衰落场景构建基于卷积残差网络信道估计模型，将接收导频、初始估计和噪声统计量共同作为网络输入，通过残差学习修正传统估计误差。进一步地，针对上行多用户检测问题，设计一种模型驱动的深度展开检测网络，将迭代线性检测过程展开为可训练层，并引入可学习步长和软判决机制，以兼顾可解释性和检测精度。最后，在统一仿真平台下对所提方法进行验证，从归一化均方误差、误码率、收敛速度和计算复杂度等方面与传统算法进行比较。

实验结果表明，所提信道估计方法能够在低信噪比和空间相关信道下获得更低的估计误差；深度展开检测网络在保持较低迭代次数的同时，可有效逼近或超过传统迭代检测性能。本文工作说明，将通信模型先验与深度学习表达能力相结合，是提升 Massive MIMO 接收端鲁棒性和实时性的可行途径。

关键词： Massive MIMO；信道估计；信号检测；深度学习；深度展开

Abstract

Massive MIMO improves spectral efficiency, energy efficiency, and spatial multiplexing capability by deploying a large number of antennas at the base station. However, the enlarged antenna array, dense user access, and complicated propagation environment also introduce high-dimensional channel estimation, severe interference, and strict real-time detection requirements. Conventional least squares, linear minimum mean square error, and iterative detection algorithms are theoretically interpretable, but they still suffer from a tradeoff between performance and complexity under pilot contamination, spatial correlation, low signal-to-noise ratio, and hardware impairments. This thesis investigates deep learning based channel estimation and signal detection methods for Massive MIMO systems, aiming to learn structural channel features and nonlinear detection mappings from data.

The thesis first reviews the system model, pilot training mechanism, channel estimation criteria, and uplink signal detection principles of Massive MIMO. Then, a convolutional residual neural network is developed for channel estimation in block fading scenarios. The received pilots, initial estimates, and noise statistics are jointly used as the network input, and residual learning is adopted to refine the conventional estimation result. Furthermore, a model-driven deep unfolded detection network is designed for uplink multi-user detection. The iterative linear detection process is unfolded into trainable layers, where learnable step sizes and soft decision operations are introduced to balance interpretability and detection accuracy. Finally, the proposed methods are evaluated on a unified simulation platform and compared with conventional algorithms in terms of normalized mean square error, bit error rate, convergence speed, and computational complexity.

Simulation results show that the proposed channel estimation method achieves lower estimation error under low signal-to-noise ratio and spatially correlated channels. The deep unfolded detection network approaches or surpasses conventional iterative detection performance with fewer iterations. The study indicates that combining communication model priors with the representation capability of deep learning is a feasible way to improve the robustness and real-time performance of Massive MIMO receivers.

Key Words: Massive MIMO, channel estimation, signal detection, deep learning, deep unfolding

目 录

摘要	I
Abstract	II
插图索引	V
表格索引	VI
专用术语注释表	VII
第一章 绪论	1
1.1 研究背景与意义	1
1.1.1 Massive MIMO 的发展需求	1
1.1.2 智能接收机的研究价值	1
1.2 国内外研究现状	2
1.2.1 传统信道估计与检测方法	2
1.2.2 深度学习辅助通信方法	2
1.3 本文主要研究内容	2
第二章 相关背景知识介绍	4
2.1 Massive MIMO 系统模型	4
2.1.1 导频训练机制	4
2.1.2 上行数据传输模型	5
2.2 传统信道估计方法	5
2.2.1 最小二乘估计	5
2.2.2 线性最小均方误差估计	5
2.3 深度学习基础	6
2.3.1 卷积神经网络	6
2.3.2 深度展开网络	6
2.4 本章小结	6
第三章 基于卷积残差网络的信道估计方法	7
3.1 问题建模	7
3.1.1 输入输出设计	7
3.1.2 损失函数设计	7
3.2 网络结构设计	7
3.2.1 残差模块	8
3.2.2 复杂度分析	8
3.3 训练与实现流程	8
3.3.1 样本生成	8
3.3.2 训练策略	8
3.4 本章小结	9
第四章 基于深度展开的上行信号检测方法	10
4.1 检测问题描述	10
4.1.1 传统线性检测	10
4.1.2 迭代检测思想	10
4.2 深度展开检测网络	10
4.2.1 层级更新结构	10
4.2.2 软判决函数	11

4.3	训练目标与部署方式	11
4.3.1	联合误差度量	11
4.3.2	在线推理流程	11
4.4	本章小结	11
第五章	仿真实验与性能分析	12
5.1	实验设置	12
5.1.1	参数配置	12
5.1.2	评价指标	12
5.2	信道估计性能分析	12
5.2.1	不同信噪比下的结果	13
5.2.2	空间相关条件下的结果	13
5.3	信号检测性能分析	13
5.3.1	误码率比较	13
5.3.2	复杂度与鲁棒性分析	13
5.4	本章小结	14
第六章	总结与展望	15
6.1	本文工作总结	15
6.2	进一步研究方向	15
参考文献		16
附录 A	程序清单	17
附录 B	攻读专业学位硕士期间撰写的论文	18
附录 C	攻读专业学位硕士期间申请的专利	19
附录 D	攻读专业学位硕士期间参加的科研项目	20

插图索引

图 2.1 Massive MIMO 上行接收端处理流程示意图 4

图 3.1 卷积残差信道估计网络结构示意图 8

图 5.1 不同检测方法误码率变化趋势示意图 13

表格索引

表 2.1 典型信道估计方法比较 5

表 5.1 仿真实验主要参数设置 12

专用术语注释表

符号说明：

符号	表示含义
M	基站接收天线数
K	上行用户数
$\mathbf{H}$	Massive MIMO 系统中用户到基站的信道矩阵
$\hat{\mathbf{H}}$	接收端得到的估计信道矩阵
$\mathbf{P}$	用户发送的导频矩阵
$\mathbf{Y}_p$	基站接收的导频信号矩阵
$\mathbf{s}$	用户发送的数据符号向量
$\mathbf{n}$	接收端加性噪声向量
τ	导频序列长度

缩略词说明：

缩写	英文全称	中文译名
5G	5th Generation	第五代移动通信
MIMO	Multiple-Input Multiple-Output	多输入多输出
LS	Least Squares	最小二乘
LMMSE	Linear Minimum Mean Square Error	线性最小均方误差
NMSE	Normalized Mean Square Error	归一化均方误差
BER	Bit Error Rate	误码率
QPSK	Quadrature Phase Shift Keying	正交相移键控

QAM Quadrature Amplitude Modu- 正交幅度调制
lation

第一章 绪论

1.1 研究背景与意义

移动通信系统正从连接人与人，逐步走向连接人、设备、数据与智能业务。高清视频、工业互联网、车联网和沉浸式交互等应用持续提高无线链路对吞吐量、可靠性和时延的要求。Massive MIMO 通过在基站侧部署大规模天线阵列，能够在同一时频资源上服务多个用户，并利用空间维度显著提升系统容量，是第五代及后续移动通信系统的重要物理层技术之一^[1,2]。

在 Massive MIMO 系统中，准确的信道状态信息是预编码、波束赋形、功率分配和信号检测的基础。随着天线数和用户数增加，信道矩阵维度快速上升，传统估计与检测算法需要处理的矩阵运算规模也随之扩大。与此同时，实际传播环境中存在空间相关、多径衰落、导频复用和硬件非理想等因素，使得理想模型下推导的线性算法难以始终获得稳定性能。因此，如何在有限导频、有限计算资源和复杂信道条件下提升接收端处理能力，具有重要研究意义。

深度学习方法具备从数据中学习非线性映射和结构特征的能力，近年来已被引入信道估计、信号检测、资源分配和端到端通信系统设计等任务。与完全黑箱的神经网络相比，将无线通信机理与神经网络结构结合，可以在保持模型可解释性的同时提升复杂场景适应性。本文围绕 Massive MIMO 接收端处理问题，研究基于深度学习的信道估计与信号检测方法。

1.1.1 Massive MIMO 的发展需求

Massive MIMO 的核心优势在于利用大规模天线阵列形成空间分辨能力。当天线数量增加时，不同用户信道向量在理想独立条件下趋于正交，基站可以通过简单线性处理获得较高阵列增益和干扰抑制能力^[3]。这一特性使 Massive MIMO 能够在不额外扩展频谱资源的情况下提升系统容量。

然而，实际系统的性能并不只由天线数量决定。空间相关会削弱用户间信道正交性；导频复用会引入导频污染；高速移动会缩短信道相干时间；低成本射频链路会带来相位噪声和量化误差。这些问题使接收机必须在准确性、复杂度与鲁棒性之间取得平衡。面向工程应用的算法不仅要具有良好误码率和估计精度，还应适应不同信噪比、天线规模和用户负载。

1.1.2 智能接收机的研究价值

传统接收机设计通常依赖明确的统计假设，例如高斯噪声、已知信道协方差和理想同步条件。当假设与实际环境存在偏差时，算法性能可能明显下降。深度学习方法能够通过训练数据学习隐含的信道结构、噪声分布和干扰模式，从而为复杂环境下的接收机设计提供新的

工具。

智能接收机并不意味着放弃通信理论。相反，通信模型可以为网络结构、损失函数和训练样本构造提供先验约束。例如，残差学习可以用于修正传统估计误差，深度展开可以将迭代检测步骤转化为可训练网络层。这种模型驱动思路有助于减少训练数据需求，并增强算法在场景变化时的可解释性。

1.2 国内外研究现状

Massive MIMO 理论研究表明，大规模天线阵列能够在多用户系统中显著提高频谱效率，并缓解小尺度衰落带来的随机性^[4]。早期研究主要关注理想信道条件下的容量分析和线性处理方法，随后逐步扩展到空间相关、导频污染、硬件非理想和网络协作等实际问题^[5,6]。

1.2.1 传统信道估计与检测方法

在信道估计方面，最小二乘算法实现简单，不需要信道统计信息，但对噪声较敏感；线性最小均方误差算法利用二阶统计信息，通常能获得更低估计误差，但需要已知或准确估计信道协方差。在信号检测方面，最大似然检测性能优越但复杂度随用户数指数增长，线性检测和迭代检测则通过牺牲部分性能换取可实现复杂度。

这些方法的共同特点是理论清晰、部署成本较低，但性能依赖模型假设。当信道维度较高、用户间干扰较强或统计信息不准确时，传统方法往往需要更长导频、更复杂矩阵求逆或更多迭代步骤。

1.2.2 深度学习辅助通信方法

深度学习辅助通信研究主要包括数据驱动和模型驱动两类。数据驱动方法直接学习输入观测与目标变量之间的映射，结构灵活但可解释性较弱；模型驱动方法将传统算法的迭代形式、优化目标或先验约束嵌入网络结构，通常具有更好的泛化能力和更低训练难度。

在 Massive MIMO 场景中，卷积网络可用于提取信道矩阵的局部相关特征，循环网络可描述时间相关信道变化，深度展开网络可模拟迭代检测或稀疏恢复过程。现有研究表明，合理利用通信先验是提升深度学习算法实用性的关键。

1.3 本文主要研究内容

本文按照“背景建模、方法设计、仿真验证、总结展望”的思路展开研究。首先介绍 Massive MIMO 系统模型及相关基础知识；其次设计基于卷积残差网络信道估计方法；然后提出基

于深度展开的上行信号检测网络；最后构建仿真实验，对所提方法的估计精度、检测性能和复杂度进行分析。

本文的主要工作包括：建立统一的上行 Massive MIMO 仿真模型；分析传统信道估计和检测算法的误差来源；设计融合传统初始估计与神经网络修正的信道估计方案；构建具有可解释层结构的深度展开检测网络；通过不同信噪比、天线规模和空间相关系数下的实验验证方法有效性。

第二章 相关背景知识介绍

本章介绍本文研究所需的 Massive MIMO 系统模型、无线信道模型、传统信道估计方法以及深度学习基础。相关内容为后续算法设计和仿真实验提供理论支撑。

2.1 Massive MIMO 系统模型

考虑单小区上行 Massive MIMO 系统，基站配置 M 根接收天线，同时服务 K 个单天线用户，通常满足 $M \gg K$ 。在一个相干块内，信道保持近似不变，上行接收信号可表示为

$$\mathbf{Y} = \mathbf{H}\mathbf{X} + \mathbf{N}, \quad (2.1)$$

其中， $\mathbf{H} \in \mathbb{C}^{M \times K}$ 表示用户到基站的信道矩阵， $\mathbf{X} \in \mathbb{C}^{K \times T}$ 表示用户发送信号， $\mathbf{N}$ 为复高斯噪声矩阵， T 为观测长度。

上行接收机的目标是在给定接收信号 $\mathbf{Y}$ 的条件下，估计信道 $\mathbf{H}$ 并恢复发送符号 $\mathbf{X}$ 。若 $\mathbf{H}$ 估计不准确，检测阶段会产生误差传播。因此，信道估计与信号检测是 Massive MIMO 接收端相互关联的两个核心问题。




图 2.1 Massive MIMO 上行接收端处理流程示意图

2.1.1 导频训练机制

在时分双工系统中，基站通常利用用户发送的上行导频估计信道。设导频矩阵为 $\mathbf{P} \in \mathbb{C}^{K \times \tau}$ ，接收导频信号为

$$\mathbf{Y}_p = \mathbf{H}\mathbf{P} + \mathbf{N}_p, \quad (2.2)$$

其中 τ 为导频长度。当导频序列相互正交且 $\tau \geq K$ 时，用户间导频干扰可以被抑制；当用户数较多或多小区复用导频时，导频污染会成为限制系统性能的重要因素。

2.1.2 上行数据传输模型

导频训练完成后，用户发送数据符号 $\mathbf{s} \in \mathbb{C}^K$ ，基站接收向量为

$$\mathbf{y} = \mathbf{H}\mathbf{s} + \mathbf{n}. \quad (2.3)$$

若已知信道矩阵，检测器可根据 $\mathbf{y}$ 恢复 $\mathbf{s}$ 。在实际系统中，检测器只能使用估计信道 $\hat{\mathbf{H}}$ ，因此检测性能同时受噪声、用户间干扰和信道估计误差影响。

2.2 传统信道估计方法

传统信道估计方法通常基于明确的统计模型设计，具有实现简单、理论成熟等优点。本文将将其作为深度学习方法的基线和初始估计来源。

2.2.1 最小二乘估计

最小二乘估计通过最小化接收导频与重构导频之间的欧氏距离获得信道估计。当导频矩阵满足 $\mathbf{P}\mathbf{P}^H = \tau\mathbf{I}$ 时，最小二乘估计可写为

$$\hat{\mathbf{H}}_{\text{LS}} = \frac{1}{\tau} \mathbf{Y}_p \mathbf{P}^H. \quad (2.4)$$

该方法不需要信道协方差信息，适用于统计信息难以获得的场景。但在低信噪比或导频长度有限时，估计结果容易受到噪声扰动。

表 2.1 典型信道估计方法比较

方法	主要优点	主要局限
LS 估计	结构简单，不依赖信道统计信息	低信噪比下对噪声敏感
LMMSE 估计	可利用统计先验降低均方误差	需要协方差信息，矩阵运算复杂
残差网络估计	能学习非线性误差修正，适应复杂信道	需要离线训练和样本构造

2.2.2 线性最小均方误差估计

线性最小均方误差估计利用信道和噪声统计信息，在均方误差意义下获得线性最优估计。与最小二乘估计相比，该方法能够在噪声较强时取得更稳定的估计性能，但需要预先获得信道协方差矩阵。对于高维 Massive MIMO 系统，协方差估计和矩阵求逆会带来额外复杂度。

2.3 深度学习基础

深度学习模型由多层可训练参数组成，能够通过大量样本学习输入到输出之间的非线性映射。对于无线通信任务，网络输入可以是接收导频、初始估计或软判决信息，输出可以是信道矩阵、发送符号概率或修正量。

2.3.1 卷积神经网络

卷积神经网络通过局部连接和权值共享提取空间结构特征。Massive MIMO 信道矩阵在天线维度和用户维度上通常存在相关性，因此可将其实部、虚部和初始估计误差视为多通道特征图进行处理。卷积结构参数量较少，适合用于信道估计中的特征增强。

2.3.2 深度展开网络

深度展开网络将传统迭代算法的每一步展开为神经网络的一层，并将步长、阈值或加权系数设置为可训练参数。与普通黑箱网络相比，深度展开网络保留了原算法的计算流程，训练参数较少，便于解释和部署。对于信号检测任务，该结构能够把线性检测、残差更新和软判决过程统一到可学习框架中。

2.4 本章小结

本章围绕 Massive MIMO 接收端处理问题，介绍了上行系统模型、导频训练机制、传统信道估计方法以及深度学习相关基础。传统方法为本文后续模型提供初始估计和可解释结构，深度学习方法则用于增强复杂信道条件下的非线性建模能力。

第三章 基于卷积残差网络的信道估计方法

本章针对低信噪比和空间相关信道下传统估计误差较大的问题，设计一种基于卷积残差网络的 Massive MIMO 信道估计方法。该方法以传统最小二乘估计为初值，通过神经网络学习估计误差的结构化修正量。

3.1 问题建模

信道估计的目标是根据接收导频 $\mathbf{Y}_p$ 和导频矩阵 $\mathbf{P}$ 恢复真实信道 $\mathbf{H}$ 。若直接从接收导频学习信道映射，网络需要同时完成导频解扩、噪声抑制和信道结构提取，训练难度较高。因此，本文先利用最小二乘方法得到初始估计 $\hat{\mathbf{H}}_{LS}$ ，再由神经网络学习残差项。

3.1.1 输入输出设计

复数信道矩阵不便直接输入常规卷积网络，本文将 $\hat{\mathbf{H}}_{LS}$ 的实部和虚部分别作为两个特征通道，并将信噪比估计量作为辅助标量嵌入网络。网络输出为残差矩阵 $\Delta\mathbf{H}$ ，最终估计结果

$$\hat{\mathbf{H}} = \hat{\mathbf{H}}_{LS} + \Delta\mathbf{H}. \quad (3.1)$$

这种设计保留了传统估计的基本趋势，使网络重点学习由噪声和相关性导致的误差结构。

3.1.2 损失函数设计

训练阶段以归一化均方误差作为主要优化目标：

$$\mathcal{L}_{NMSE} = \frac{\|\mathbf{H} - \hat{\mathbf{H}}\|_F^2}{\|\mathbf{H}\|_F^2}. \quad (3.2)$$

为避免网络在高信噪比样本中过拟合细小噪声，训练集覆盖多个信噪比区间，并在每个批次中随机抽取不同空间相关系数的信道样本。该策略有助于提升模型对场景变化的鲁棒性。

3.2 网络结构设计

所提网络由输入映射层、多个残差卷积模块和输出重构层组成。输入映射层将实部、虚部和辅助信息映射到高维特征空间；残差模块用于提取天线维度和用户维度上的局部相关结构；输出层生成与信道矩阵同维度的残差修正量。




图 3.1 卷积残差信道估计网络结构示意图

3.2.1 残差模块

每个残差模块包含两层二维卷积、批归一化和非线性激活函数。模块输入与卷积输出通过跳连相加，使网络可以学习相对于输入特征的增量变化。残差结构能够缓解深层网络训练中的梯度衰减问题，并使模型更适合处理“初始估计已经接近真实值”的任务。

3.2.2 复杂度分析

与线性最小均方误差估计中的高维矩阵求逆相比，卷积残差网络推理阶段主要由卷积运算组成，参数量与卷积核大小和通道数相关，而不直接随样本数增长。对于固定天线规模的基站，网络可离线训练、在线推理，适合在接收端采用并行硬件加速。

3.3 训练与实现流程

训练数据由仿真信道模型生成。每个样本包括真实信道、导频矩阵、接收导频和信噪比标签。为提高模型泛化性，训练集中随机改变用户位置、大尺度衰落、空间相关系数和噪声功率。

3.3.1 样本生成

信道样本采用瑞利衰落与指数相关模型组合生成。首先产生独立复高斯矩阵，再通过相关矩阵引入天线间相关性，最后叠加大尺度衰落系数。导频序列采用正交序列，接收导频由系统模型计算并加入复高斯噪声。

3.3.2 训练策略

网络采用小批量随机梯度下降类优化器训练，学习率随验证集损失变化自适应调整。训练过程中保留验证集性能最优的模型参数，并采用早停策略避免过拟合。为保证公平比较，测试阶段所有方法使用相同信道样本和噪声实现。

3.4 本章小结

本章提出了基于卷积残差网络的 Massive MIMO 信道估计方法。该方法以最小二乘估计为初值，通过残差学习提升复杂信道条件下的估计精度。网络结构充分利用信道矩阵的局部相关特征，兼顾性能提升与推理复杂度。

第四章 基于深度展开的上行信号检测方法

本章研究 Massive MIMO 上行多用户信号检测问题。针对传统迭代检测在复杂度和收敛速度方面的限制，设计一种基于深度展开思想的检测网络，将线性迭代过程转化为可训练的层级结构。

4.1 检测问题描述

在上行数据传输阶段，基站接收信号满足 $\mathbf{y} = \hat{\mathbf{H}}\mathbf{s} + \mathbf{n}$ ，其中 $\hat{\mathbf{H}}$ 为估计信道。检测任务是在给定 $\mathbf{y}$ 和 $\hat{\mathbf{H}}$ 的条件下恢复发送符号 $\mathbf{s}$ 。当用户数增加或调制阶数提高时，最优检测复杂度迅速上升，实际系统通常采用线性检测或低复杂度迭代检测。

4.1.1 传统线性检测

匹配滤波、迫零和最小均方误差检测是常见线性检测方法。匹配滤波复杂度低，但在用户间干扰较强时性能有限；迫零检测可以消除多用户干扰，但会放大噪声；最小均方误差检测在干扰抑制和噪声增强之间取得折中。线性检测适合大规模天线场景，但在信道估计误差存在时仍有改进空间。

4.1.2 迭代检测思想

迭代检测通过多次更新符号估计逐步减小残差误差。典型过程包括梯度更新、干扰抵消和软判决映射。其性能与迭代步长、初始化方式和停止准则密切相关。固定参数的迭代算法难以同时适配不同信噪比和信道相关条件，而深度展开提供了将这些参数学习化的途径。

4.2 深度展开检测网络

本文将迭代检测过程展开为 L 层网络。每一层根据当前符号估计、接收残差和信道矩阵更新软符号，并通过可训练参数调整更新幅度。网络初始输入采用线性最小均方误差检测结果，以提高收敛起点质量。

4.2.1 层级更新结构

第 l 层的更新可表示为

$$\mathbf{z}^{(l)} = \mathbf{s}^{(l)} + \alpha_l \hat{\mathbf{H}}^H (\mathbf{y} - \hat{\mathbf{H}}\mathbf{s}^{(l)}), \quad (4.1)$$

其中 α_l 为可训练步长。随后, $\mathbf{z}^{(l)}$ 经过软判决函数得到下一层估计 $\mathbf{s}^{(l+1)}$ 。与传统固定步长迭代相比, 可训练步长能够根据训练数据自动适配不同层的误差特征。

4.2.2 软判决函数

对于 QPSK 或 QAM 调制, 硬判决会造成不可导问题, 不利于端到端训练。本文采用平滑软判决函数近似星座映射, 使网络在训练阶段能够反向传播梯度, 在测试阶段再根据最终输出执行硬判决。软判决还可输出符号置信度, 为后续译码模块提供可靠性信息。

4.3 训练目标与部署方式

检测网络训练以发送符号为监督标签。损失函数综合考虑符号均方误差和交叉熵判决损失, 使模型既关注连续估计精度, 也关注最终离散符号判决。

4.3.1 联合误差度量

训练损失定义为

$$\mathcal{L}_{\text{det}} = \lambda \|\mathbf{s} - \hat{\mathbf{s}}\|_2^2 + (1 - \lambda) \mathcal{L}_{\text{CE}}, \quad (4.2)$$

其中 $\mathcal{L}_{\text{CE}}$ 为符号类别交叉熵, λ 为权重系数。该设计能够减少仅使用均方误差时对星座边界不敏感的问题。

4.3.2 在线推理流程

在线阶段, 基站先利用第三章方法获得信道估计, 再将接收数据和估计信道输入检测网络。由于网络层数固定, 推理时延可提前评估, 适合实时接收机部署。若系统调制方式或天线规模变化较大, 可通过迁移学习对部分层参数进行微调。

4.4 本章小结

本章提出了一种基于深度展开的 Massive MIMO 上行信号检测方法。该方法将传统迭代检测过程转化为可训练网络, 在保留算法结构的同时提高参数自适应能力。通过软判决和联合损失设计, 网络能够兼顾训练可导性和最终判决性能。

第五章 仿真实验与性能分析

本章构建仿真实验平台，对第三章和第四章提出的方法进行验证。实验从信道估计精度、信号检测误码率、复杂度和鲁棒性等角度展开分析。

5.1 实验设置

仿真考虑单小区上行 Massive MIMO 系统，基站天线数设置为 $M = 64$ 或 $M = 128$ ，用户数设置为 $K = 8$ 或 $K = 16$ 。信道采用瑞利衰落与空间相关模型，噪声为独立复高斯噪声。调制方式主要采用 QPSK，并在部分实验中扩展至 16QAM。

表 5.1 仿真实验主要参数设置

参数	取值
基站天线数 M	64, 128
用户数 K	8, 16
调制方式	QPSK, 16QAM
信噪比范围	0 dB 至 20 dB
导频长度 τ	$\tau = K$
评价指标	NMSE, BER, 推理层数, 矩阵运算量

5.1.1 参数配置

信噪比范围设置为 0 dB 至 20 dB，导频长度取 $\tau = K$ 。训练集、验证集和测试集相互独立生成，避免样本泄漏。深度学习模型离线训练，测试阶段固定参数。传统对比方法包括最小二乘估计、线性最小均方误差估计、匹配滤波检测和线性最小均方误差检测。

5.1.2 评价指标

信道估计性能采用归一化均方误差衡量，信号检测性能采用误码率衡量。复杂度分析主要比较矩阵求逆次数、乘加运算量和网络推理层数。鲁棒性实验考察训练条件与测试条件不完全一致时的性能变化。

5.2 信道估计性能分析

在低信噪比条件下，最小二乘估计明显受到噪声影响，归一化均方误差较高。线性最小均方误差估计利用信道统计信息后性能有所改善，但当空间相关系数估计不准确时，其优势

会减弱。所提卷积残差网络能够基于初始估计进一步抑制噪声扰动，因此在多个信噪比区间均获得更低估计误差。

5.2.1 不同信噪比下的结果

随着信噪比升高，各类估计方法的误差均下降。所提方法在低信噪比区域提升更明显，说明残差网络能够有效学习噪声造成的结构化偏差。在高信噪比区域，传统估计已经较为准确，深度学习方法仍能保持稳定改进，但增益相对减小。

5.2.2 空间相关条件下的结果

当天线间空间相关增强时，信道矩阵有效秩降低，用户间可分性下降。实验表明，最小二乘估计无法利用相关结构，线性最小均方误差估计依赖协方差准确性，而卷积残差网络能够从训练样本中学习相关模式，对相关系数变化具有较好适应性。

5.3 信号检测性能分析

在相同信道估计条件下，深度展开检测网络的误码率低于匹配滤波检测，并在多数场景下优于线性最小均方误差检测。其主要原因在于网络通过多层残差更新逐步消除多用户干扰，同时可训练参数能够自动调整不同迭代阶段的更新强度。

5.3.1 误码率比较

低信噪比区域中，检测性能主要受噪声和信道估计误差影响。深度展开网络利用训练数据学习噪声下的软判决边界，因此误码率下降更快。中高信噪比区域中，多用户干扰成为主要限制因素，展开网络通过迭代残差更新进一步提升符号分辨能力。

信噪比	0 dB	5 dB	10 dB	15 dB
传统检测	高	较高	中	较低
深度展开检测	较高	中	较低	低

误码率随信噪比升高而下降，深度展开检测下降趋势更明显。

图 5.1 不同检测方法误码率变化趋势示意图

5.3.2 复杂度与鲁棒性分析

深度展开网络推理层数固定，不需要在测试阶段执行不确定次数的迭代。与高复杂度最优检测相比，其计算量可控；与传统线性检测相比，虽然增加了若干层矩阵向量运算，但换

来了更好的检测性能。鲁棒性实验显示，当测试信道相关系数与训练集存在适度偏差时，网络性能仍保持稳定，说明模型具有一定泛化能力。

5.4 本章小结

本章通过仿真实验验证了所提信道估计和信号检测方法的有效性。实验结果表明，卷积残差网络能够提升复杂信道条件下的估计精度，深度展开检测网络能够在有限复杂度下改善误码率表现。整体来看，模型驱动深度学习方法适合用于 Massive MIMO 接收端增强。

第六章 总结与展望

6.1 本文工作总结

本文围绕 Massive MIMO 系统中的信道估计与上行信号检测问题，研究了深度学习辅助接收机设计方法。首先，本文分析了 Massive MIMO 技术背景、传统估计与检测算法特点以及复杂无线环境带来的挑战。其次，针对传统最小二乘估计在低信噪比和空间相关场景下误差较大的问题，提出基于卷积残差网络信道估计方法，通过学习残差修正量提升估计精度。再次，针对多用户信号检测中的复杂度与性能折中问题，提出基于深度展开的检测网络，将迭代检测过程转化为可训练层结构。最后，本文通过统一仿真平台比较了所提方法与传统算法的性能，结果表明模型驱动深度学习方法能够在估计精度、误码率和推理复杂度之间取得较好平衡。

本文的核心结论是：在 Massive MIMO 接收端处理中，单纯依赖数据驱动模型容易缺乏可解释性，单纯依赖传统模型又难以适应复杂环境。将通信理论先验与神经网络表达能力结合，可以更有效地利用有限训练数据，并提高算法在不同信道条件下的鲁棒性。

6.2 进一步研究方向

后续研究可从以下几个方面继续展开。第一，本文主要基于仿真数据训练和验证模型，未来可引入实测信道数据，进一步评估模型在真实传播环境中的泛化能力。第二，本文重点研究单小区上行场景，后续可扩展至多小区协作、毫米波 Massive MIMO 和超大规模天线阵列系统。第三，深度学习模型的在线更新、轻量化压缩和硬件部署仍需深入研究，以满足实际基站对时延、功耗和存储资源的限制。第四，可进一步探索信道估计、检测和译码的联合优化，使接收机从模块级增强走向系统级协同设计。

参考文献

- [1] Marzetta T L. Noncooperative Cellular wireless with Unlimited Numbers of Base Station Antennas[J]. IEEE Transactions on Wireless Communications, 2010, 9(11): 3590–3600.
- [2] Larsson E G, Edfors O, Tufvesson F, et al. Massive MIMO for next generation wireless systems[J]. IEEE Communications Magazine, 2014, 52(2): 186–195.
- [3] Rusek F, Persson D, Lau B K, et al. Scaling Up MIMO: Opportunities and Challenges with Very Large Arrays [J]. IEEE Signal Processing Magazine, 2013, 30(1): 40–60.
- [4] Hoydis J, ten Brink S, Debbah M. Massive MIMO in the UL/DL of Cellular Networks: How Many Antennas Do We Need?[J]. IEEE Journal on Selected Areas in Communications, 2013, 31(2): 160–171.
- [5] Sanguinetti L, Björnson E, Hoydis J. Toward Massive MIMO 2.0: Understanding Spatial Correlation, Interference Suppression, and Pilot Contamination[J]. IEEE Transactions on Communications, 2020, 68(1): 232–257.
- [6] Venkatesan S, Lozano A, Valenzuela R. Network MIMO: Overcoming Intercell Interference in Indoor Wireless Systems[C]. Proceedings of the Asilomar Conference on Signals, Systems and Computers (ACSSC). 2007: 83–87.

附录 A 程序清单

本文为论文内容填充稿，未附独立程序清单。后续若补充仿真实验代码，可按照章节列出数据生成、模型训练、信道估计、信号检测和性能绘图等程序文件。

附录 B 攻读专业学位硕士期间撰写的论文

[1] 暂无。

附录 C 攻读专业学位硕士期间申请的专利

[1] 暂无。

附录 D 攻读专业学位硕士期间参加的科研项目

[1] 暂无。